

Papoi: avaliação de modelos de linguagem para um tutor escolar acessível por voz e offline

Luiz Augusto, Arthur Rodrigues, Maria Eduarda Queiroz
Instituto Federal da Paraíba campus Esperança (IFPB-ES)
PB-121, s/n, Esperança – PB – Brazil

Repositórios do projeto: [GitHub](#) | [modelo](#) | [dataset](#)

Abstract. This paper presents Papoi, an offline voice-based school tutoring assistant designed for accessibility scenarios. The system integrates speech recognition, a local large language model and speech synthesis in a CPU-only environment. We compare local, free cloud and commercial models through a rubric focused on clarity, pedagogical adequacy, brevity and accessible language. The results indicate that the fine-tuned and quantized local model is viable for offline tutoring, although cloud models still achieve higher pedagogical scores and lower latency.

Resumo. Este artigo apresenta o Papoi, um assistente de tutoria escolar por voz, pensado para cenários de acessibilidade e uso offline. O sistema integra reconhecimento de fala, modelo de linguagem local e síntese de voz em ambiente sem GPU dedicada. Foram comparados modelos locais, APIs gratuitas e modelos comerciais por meio de uma rubrica que considera clareza, adequação pedagógica, brevidade e linguagem acessível. Os resultados indicam que o modelo local ajustado e quantizado é viável para tutoria offline, embora modelos em nuvem ainda tenham maior qualidade e menor latência.

Introdução

Ferramentas de inteligência artificial generativa já aparecem em ambientes educacionais como chatbots e assistentes de estudo. Porém, muitas dependem de internet, APIs pagas e digitação, o que cria barreiras para alunos com dificuldade de leitura, problemas motores, deficiência visual ou acesso instável à rede. O problema investigado foi como construir e avaliar um tutor escolar por voz, executado localmente e sem custo operacional após a instalação.

O Papoi foi desenvolvido em português do Brasil: o aluno fala uma pergunta, o sistema transcreve a fala, gera uma resposta com um modelo de linguagem e devolve o áudio sintetizado. O objetivo não foi superar modelos comerciais, mas verificar se modelos pequenos e locais conseguem oferecer uma experiência útil, segura e acessível.

A contribuição do trabalho é a avaliação comparativa de modelos de linguagem em um pipeline completo de voz em CPU, considerando qualidade pedagógica, redirecionamento de perguntas fora do escopo, remoção de markdown para TTS e viabilidade em hardware limitado.

Fundamentação Teórica

Sistemas tutores inteligentes oferecem apoio individualizado ao estudante por meio de feedback e adaptação das respostas ao nível do aprendiz. Estudos de metanálise indicam ganhos quando esses sistemas conseguem orientar o aluno de forma imediata e personalizada (KULIK; FLETCHER, 2016). Com os grandes modelos de linguagem,

parte dessas capacidades passou a ser explorada por chatbots educacionais, capazes de dialogar e reformular explicações.

No Papoi, a acessibilidade é requisito de projeto. As diretrizes de Desenho Universal para Aprendizagem defendem múltiplas formas de engajamento, representação e ação (CAST, 2018), o que se relaciona com uma interface por fala. A escolha por STT e TTS reduz a dependência de leitura e digitação.

O módulo de fala utiliza Whisper, proposto para reconhecimento robusto de fala em larga escala (RADFORD et al., 2022), por meio do faster-whisper. O ajuste do modelo de linguagem foi inspirado em LoRA e QLoRA, métodos que reduzem parâmetros treináveis e consumo de memória durante o fine-tuning (HU et al., 2021; DETTMERS et al., 2023).

Trabalhos Relacionados

A literatura sobre tutores inteligentes inclui sistemas baseados em regras, modelos cognitivos e aprendizagem de máquina. VanLehn (2011) destaca que sistemas computacionais podem se aproximar da tutoria humana quando oferecem feedback adequado. Revisões recentes também apontam crescimento de soluções multimodais e baseadas em modelos de linguagem, com desafios de segurança, escalabilidade e adequação pedagógica.

O Papoi se diferencia por priorizar uma solução offline, leve e orientada à fala. Em vez de depender apenas de modelos pagos em nuvem, compara modelos locais, APIs gratuitas e modelos comerciais, buscando equilíbrio entre qualidade, privacidade, custo e acessibilidade.

Metodologia

A arquitetura foi organizada em três módulos integrados por FastAPI. O primeiro transcreve a fala com faster-whisper, modelo small em CPU e filtro de atividade de voz. O segundo envia a pergunta ao modelo local no Ollama, mantendo histórico por sessão e aplicando um prompt pedagógico com escopo escolar, linguagem simples, brevidade e ausência de markdown. O terceiro gera o áudio com Piper e executa limpeza de marcações antes da síntese.

Os testes locais foram feitos sem GPU dedicada, em um Intel i3-1115G4, 12 GB de RAM e SSD. A restrição orientou a seleção dos modelos e tornou inviáveis alternativas com alto consumo de memória. A avaliação ocorreu em cinco fases: modelos locais, refinamento de prompt, APIs gratuitas, modelos comerciais e modelo ajustado por fine-tuning.

Foi utilizado um banco fixo de dez perguntas, abrangendo matemática, ciências, português, programação e duas perguntas fora do escopo. As respostas foram avaliadas de 1 a 5 em clareza, adequação pedagógica, brevidade, acessibilidade linguística e redirecionamento. O dataset de fine-tuning possui 323 exemplos no formato instruction, input e output, com linguagem simples e foco em explicação oral.

Resultados

Na primeira fase, o melhor resultado local foi obtido pelo qwen2.5:3b com temperatura 0.7, média 3,13. Apesar disso, o modelo apresentou alucinações em

ciências e baixo redirecionamento. O gemma3:4b teve média inicial menor, 2,90, mas mostrou melhor conhecimento científico e maior estabilidade em português. Após o aumento de MAX_TOKENS de 300 para 500 e refinamento do prompt, o gemma3:4b tornou-se o melhor modelo local sem ajuste fino, atingindo média 3,35.

A comparação com APIs mostrou a distância entre soluções locais e modelos maiores. O llama-3.3-70b via Groq alcançou média 4,05 e latência de 1,19 segundo, enquanto o gemma local ficou em torno de 32 segundos. Na etapa comercial, o melhor desempenho foi do Claude Sonnet 4.6, com média 4,53. Modelos em nuvem foram mais consistentes, mas não atendem ao requisito offline.

Tabela 1. Síntese dos principais modelos avaliados.

Modelo	Média	Latência	Offline	Formato	Recomendação
Claude Sonnet 4.6	4,53	nuvem	não	adequado	melhor qualidade
llama-70b (Groq)	4,05	1,19s	não	adequado	fallback gratuito
gemma3:4b	3,35	32,3s	sim	com markdown	baseline local
papoi_q4 0.7	3,23	31,4s	sim	sem markdown	recomendado
qwen2.5:3b	2,85	19,2s	sim	instável	rápido, menor qualidade

Na fase de fine-tuning, a versão FP16 gerou timeout na pergunta de frações e foi considerada inviável em CPU. A versão quantizada Q4_K_M completou os testes, obteve média 3,23 com temperatura 0.7, eliminou markdown e manteve qualidade adequada em oito das dez perguntas. A principal falha persistente foi o redirecionamento da pergunta sobre futebol, indicando limitação de modelos locais menores.

Conclusões

Os resultados indicam que o Papoi é viável como tutor escolar acessível por voz e offline. A solução local não alcançou a qualidade de modelos comerciais, mas apresentou vantagens importantes: privacidade, custo operacional zero, funcionamento sem internet e compatibilidade com hardware básico. O papoi_q4 com temperatura 0.7 foi a melhor opção por equilibrar qualidade, estabilidade, ausência de markdown e tempo aceitável.

Como limitações, destacam-se a latência elevada, a dificuldade de redirecionar certas perguntas fora do escopo e o conjunto de avaliação pequeno. Trabalhos futuros devem ampliar o dataset, testar com estudantes reais, medir o STT em ambientes ruidosos e implementar fallback para API gratuita quando houver conexão disponível.

Referências

- CAST. Universal Design for Learning Guidelines version 2.2. Wakefield: CAST, 2018. Disponível em: <<https://udlguidelines.cast.org>>. Acesso em: 14 jun. 2026.
- DETTMERS, Tim; PAGNONI, Artidoro; HOLTZMAN, Ari; ZETTLEMOYER, Luke. QLoRA: efficient finetuning of quantized LLMs. arXiv, 2023. Disponível em: <<https://arxiv.org/abs/2305.14314>>. Acesso em: 14 jun. 2026.
- HU, Edward J. et al. LoRA: low-rank adaptation of large language models. arXiv, 2021. Disponível em: <<https://arxiv.org/abs/2106.09685>>. Acesso em: 14 jun. 2026.
- KULIK, James A.; FLETCHER, J. D. Effectiveness of intelligent tutoring systems: a meta-analytic review. Review of Educational Research, v. 86, n. 1, p. 42-78, 2016.
- RADFORD, Alec et al. Robust speech recognition via large-scale weak supervision. arXiv, 2022. Disponível em: <<https://arxiv.org/abs/2212.04356>>. Acesso em: 14 jun. 2026.
- SYSTRAN. faster-whisper: faster Whisper transcription with CTranslate2. GitHub, 2026. Disponível em: <<https://github.com/SYSTRAN/faster-whisper>>. Acesso em: 14 jun. 2026.
- VANLEHN, Kurt. The relative effectiveness of human tutoring, intelligent tutoring systems, and other tutoring systems. Educational Psychologist, v. 46, n. 4, p. 197-221, 2011.
- VOICE-TUTOR-A11Y. Repositório do projeto Papoi. GitHub, 2026. Disponível em: <<https://github.com/06Augusto-ziuL/voice-tutor-a11y>>. Acesso em: 14 jun. 2026.